

תחבורה עירונית וחכמה

אופטימיזציה של מערכי נסיעות שיתופיות

1. הגדרת עולם הבעיה

הבעיה העסקית/החברתית: בערים גדולות קיים חוסר התאמה מתמיד בין היצע כלי הרכב השיתופיים (מוניות, רכבים, אופניים) לבין הביקוש המשתנה לאורך הזמן והמרחב. התוצאה: זמני המתנה ארוכים לנוסעים באזורים מסוימים, רכבים ריקים שמסתובבים ללא ביקוש באזורים אחרים, עומסי תנועה מיותרים וזיהום אוויר.

מטרת הפרויקט: לבנות מערכת המנתחת מאות מיליוני נסיעות היסטוריות ומשלבת מודל ML לחיזוי הביקוש לכלי רכב שיתופיים לפי רובע גיאוגרפי $\times$ חלון זמן, על בסיס המשתנים: מזג אוויר, שעה ביממה, יום בשבוע, עונה ואירועים מיוחדים (משחקי ספורט, מופעים, חגים).

שאלות מחקר מרכזיות:

- כיצד מתפלג הביקוש במרחב ובזמן? (clustering של אזורי ביקוש)
- מהם הגורמים המשפיעים ביותר על הביקוש? (גשם, שעות שיא, אירועים)
- האם ניתן לחזות את הביקוש בשעה/אזור הבא ברמת דיוק שימושית?

אתגרים טכנולוגיים מרכזיים:

- עיבוד נתונים בקנה מידה של מאות מיליוני שורות (Big Data) - עיבוד מבוזר, הנתונים אינם נכנסים לזיכרון של מכונה בודדת.
- טיפול בנתונים מרחביים בקנה מידה גדול.
- סקלינג של אלגוריתמי clustering ו-ML על Cluster בענן.
- **מדדי הצלחה:** RMSE/MAE על חיזוי הביקוש, השוואה מול baseline נאיבי (ממוצע היסטורי), וזמן ריצת ה-pipeline.

2. מקור הנתונים — NYC TLC Trip Record Data

הקישור הרשמי [nyc.gov/site/tlc/about/tlc-trip-record-data.page](https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page) הוא הפורטל של רשות המוניות והלימוזינות של ניו יורק (TLC). זהו אחד ממאגרי הנתונים הציבוריים הגדולים והנפוצים ביותר לעיבוד Big Data.

מה כולל המאגר:

- רשומות נסיעה משנת 2009 ואילך, מאות מיליוני נסיעות בשנה, בפורמט Parquet (יעיל לעיבוד עמודתי).
- ארבעה סוגי שירות: Yellow Taxi (מנהטן בעיקר), Green Taxi (רובעים חיצוניים), For-Hire Vehicles (FHV), Uber/Lyft - High-Volume FHV.

שדות מרכזיים בכל רשומה:

- חותמות זמן: tpep_pickup_datetime, tpep_dropoff_datetime (מאפשרים פילוח לפי שעה/יום).
- מיקום: PULocationID, DOLocationID — מזהי אזור (Taxi Zones, 263 אזורים). חשוב לציין שב-2016 חל מעבר מקואורדינטות lat/long מדויקות ל-Zone IDs מטעמי פרטיות.
- מדדים: מספר נוסעים, מרחק, תעריף, סוג תשלום, טיפ.

נתונים משלימים נדרשים:

- Taxi Zone Shapefiles (גיאומטריות הפוליגונים של האזורים) — מסופקים באותו עמוד, נחוצים לעיבוד הגיאומטריה.
- מזג אוויר (NOAA / Open-Meteo API), לוח אירועים (משחקי MSG, ברודוויי), וחגים.

יתרון לפרויקט:

נפח אמיתי שמצדיק עיבוד מבוצר, מבנה נקי יחסית, ותיעוד עשיר. הסיכון העיקרי: ניקוי נתונים (נסיעות עם מרחק 0, חותמות זמן שגויות, ו-outliers בתעריף).

3. ארכיטקטורה ראשונית מוצעת

שלב	טכנולוגיה (מה בפועל)	היכן רץ	מה עושים
אחסון נתונים	Parquet files, CSV	דיסק מקומי / HDFS	טעינת קובצי TLC מ-NYC.gov לפי חודש.
עיבוד Batch	PySpark RDD/DataFrame	BigDataVM	ניקוי נתונים, סינון נסיעות שגויות, אגרגציה לפי $zone \times hour \times day_of_week$.
Geospatial join	PySpark	BigDataVM	חיבור LocationID לשם האזור. אין lookup — Sedona table פשוט מה-Shapefile של TLC.
קלסטרינג	Spark MLlib K-Means	BigDataVM	זיהוי אשכולות של ביקוש לפי אזור ושעה. K-Means מבוצר - הלב של הפרויקט.
Streaming (אופציה)	Kafka + Spark Streaming	BigDataVM	הזרמת שורות נסיעה כ-events ל-Consumer topic. מחשב ביקוש בזמן אמת לפי batch.
ניתוח תוצאות	Spark MLlib + Jupyter	BigDataVM	ויזואליזציה של אשכולות, גרפים לפי שעה/אזור, השוואת WCSS ל-K שונים (elbow method).
הגשה	Jupyter Notebook	BigDataVM	קובץ ipynb עם כל ה-pipeline - טעינה, ניקוי, clustering, תוצאות. כולל README.TXT.

4. מאמרים אקדמיים רלוונטיים

1. Apache Sedona GeoSpark — המנוע הגיאומטרי

Yu, J., Zhang, Z., & Sarwat, M. (2019). Spatial data management in apache spark: the GeoSpark perspective and beyond. *Geoinformatica*, 23(1), 37–78

[Spatial data management in apache spark: the GeoSpark perspective and beyond | Geoinformatica | Springer Nature Link](#)

הסבר: המאמר היסודי המתאר את הארכיטקטורה של GeoSpark/Sedona - כיצד מבצעים אינדוקס מרחבי (Quad-Tree, R-Tree) ו-spatial joins מבזרים על Spark. רלוונטי ישירות לשלב ה-spatial join בין נקודות הנסיעה לפוליגוני האזורים.

2. חיזוי ביקוש למוניות עם Deep Learning

Yao, H., Wu, F., Ke, J., et al. (2018). Deep Multi-View Spatial-Temporal Network for Taxi Demand Prediction. *AAAI Conference on Artificial Intelligence*

[Deep Multi-View Spatial-Temporal Network for Taxi Demand Prediction \[1802.08714\]](#)

הסבר: מציג ארכיטקטורת DMVST-Net המשלבת מבט מרחבי (CNN), זמני (LSTM) וסמנטי (גרף דמיון בין אזורים) לחיזוי ביקוש למוניות. בסיס תיאורטי מצוין לשלב ה-ML ולהבנת חשיבות שילוב מימדי המרחב והזמן.

3. ניתוח קלסטרינג של דפוסי נסיעה בנתוני NYC Taxi

Ferreira, N., Poco, J., Vo, H. T., Freire, J., & Silva, C. T. (2013). Visual Exploration of Big Spatio-Temporal Urban Data: A Study of New York City Taxi Trips. *IEEE TVCG (VAST)*, 19(12), 2149–2158

[Visual Exploration of Big Spatio-Temporal Urban Data: A Study of New York City Taxi Trips | IEEE Journals & Magazine](#)

הסבר: מחקר מכון המשתמש במאגר NYC Taxi עצמו לניתוח חזותי-מרחבי-זמני של דפוסי נסיעה. רלוונטי להבנת המאגר, לזיהוי אזורי ביקוש ולשלב ה-clustering והויזואליזציה.